

◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡

Motivation

Miller, et al.[3] 通过对皮质层 ECoG 活动研究发现, MI 引起的皮质活动变化幅度约为 ME (运动执行) 的 25%, 在实际运动中, 神经元群体的放电率可能比运动想象时高出 3 倍以上。然而, 当受试者学会在简单的反馈任务中使用 MI 在线反馈来控制计算机光标时, 想象引起的活动变化显著增强, 甚至超过了肌肉活动导致肢体明显移动的实际行为。通过简单的运动想象反馈任务, 整个运动皮层中的神经元群体活动得到了显著增强。这种动态增强尤其在主要运动皮层中观察到, 这表明在非常短的时间尺度内 (小于 10 分钟), 大脑中的神经动力学发生了动态的重构。在这种在线培训几分钟后, 两名受试者报告说, 思考如何将光标上下移动取代了 MI。

期刊信息

Computers in Biology and Medicine(CIBM), IF=7.7 重庆大学电气工程学院,
2023 年 10 月.

中科院SCI期刊分区 (2023年12月最新升级版) ①	点击查看中科院SCI期刊分区趋势图			
	大类学科	小类学科	Top期刊	综述期刊
医学	2区	BIOLOGY 生物学	1区	是
		MATHEMATICAL & COMPUTATIONAL BIOLOGY 数学与计算生物学	1区	
		COMPUTER SCIENCE, INTERDISCIPLINARY APPLICATIONS 计算机: 跨学科应用	2区	
		ENGINEERING, BIOMEDICAL 工程: 生物医学	2区	
中科院SCI期刊分区 (2022年12月升级版)	工程技术	MATHEMATICAL & COMPUTATIONAL BIOLOGY 数学与计算生物学	1区	否
		BIOLOGY 生物学	2区	
		ENGINEERING, BIOMEDICAL 工程: 生物医学	2区	
		COMPUTER SCIENCE, INTERDISCIPLINARY APPLICATIONS 计算机: 跨学科应用	3区	
中科院SCI期刊分区 (2021年12月旧的升级版)	工程技术	BIOLOGY 生物学	2区	否
		MATHEMATICAL & COMPUTATIONAL BIOLOGY 数学与计算生物学	2区	
		COMPUTER SCIENCE, INTERDISCIPLINARY APPLICATIONS 计算机: 跨学科应用	3区	
		ENGINEERING, BIOMEDICAL 工程: 生物医学	3区	

Abstract

- 基于 MI 的 BCI 需要漫长而繁琐的校准过程。然而，长时间的校准不可避免地会导致精神疲劳，从而影响脑电图的可分离性。另一方面，标记数据不足会导致训练后的解码器不可靠。目前，迁移学习，多任务学习，数据对齐已被用来解决上述问题。
- 半监督学习 (semi-supervised learning, SSL) 从现成的、信息丰富的、未标记的数据中学习来解决。本文的算法由极限学习机 (ELM) 改进而来，根据在线喂入新的数据，一个辅助分类器得到“伪标签”，以半监督的方式迭代更新 ELM。
- 利用 SMOTE-ENN 算法进行数据增广和类别平衡。

Background Knowledge

极限学习机 (Extreme Learning Machines, ELM) 是一种求解单层前馈神经网络的学习算法。与反向传播 (BP) 学习算法相比, ELM 的输入权重通过随机分配之后保持不变, 仅通过更新输出权重 β 来学习。

$$h_i(x) = h(\omega_i x + b_i)$$

$$f_L(x) = \sum_{i=1}^L \beta_i h(\omega_i, b_i, x)$$

$$\arg \min_{\beta} \|\mathbf{Y} - \mathbf{H}(x)\beta\|_2$$




图: 极限学习机

流程图

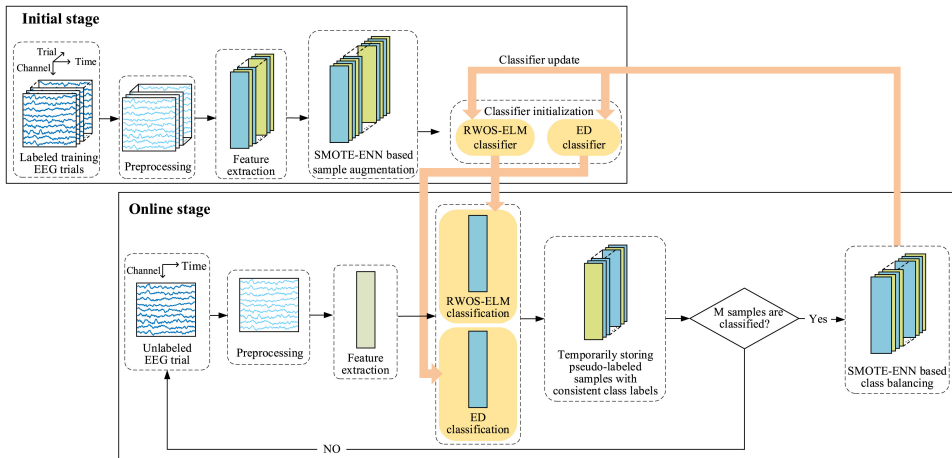


图: SE-IRWOS-ELM 的流程图

Method: 基于 RWOS-ELM 的基础分类器

1. 基于 RWOS-ELM 的基础分类器

给定初始训练集 $\mathcal{D}_0 = \{\mathbf{x}_i, \mathbf{y}_i\}$, $i = 1, 2, \dots, N_0$, $\mathbf{x}_i \in \mathbb{R}^n$ 和 $\mathbf{y}_i \in \mathbb{R}^m$ 是标记输入向量和输出向量, 其中 n 是特征维度, m 是类别数。

L 个隐藏节点的 ELM 的数学模型描述为

$$\sum_{j=1}^L \beta_j G(\mathbf{a}_j, b_j, \mathbf{x}_i) = \mathbf{y}_i, \quad i = 1, 2, \dots, N_0$$

其中, $\mathbf{a}_j \in \mathbb{R}^n$ 和 $b_j \in \mathbb{R}$ 是输入权重向量和偏置, $\beta_j \in \mathbb{R}^m$ 是输出权重向量。 $G(\cdot)$ 是特征映射函数, 可以是非线性分段连续函数, 例如 sigmoid 函数:

$$G(\mathbf{a}_j, b_j, \mathbf{x}_i) = \frac{1}{1 + \exp(-\mathbf{a}_j^T \mathbf{x}_i - b_j)}$$

Method: 基于 RWOS-ELM 的基础分类器

简洁描述为

$$\mathbf{H}_0 \boldsymbol{\beta}^{(0)} = \mathbf{Y}^{(0)}$$

其中, $\boldsymbol{\beta}^{(0)} = [\boldsymbol{\beta}_1, \boldsymbol{\beta}_2, \dots, \boldsymbol{\beta}_L]^T \in \mathbb{R}^{L \times m}$ 是输出权重向量,
输出矩阵 $\mathbf{Y}^{(0)}$

$$\mathbf{Y}^{(0)} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_{N_0}]^T \in \mathbb{R}^{N_0 \times m}$$

\mathbf{H}_0 是初始隐藏层输出矩阵

$$\mathbf{H}_0 = \begin{bmatrix} G(\mathbf{a}_1, b_1, \mathbf{x}_1) & \cdots & G(\mathbf{a}_L, b_L, \mathbf{x}_1) \\ \vdots & \ddots & \vdots \\ G(\mathbf{a}_1, b_1, \mathbf{x}_{N_0}) & \cdots & G(\mathbf{a}_L, b_L, \mathbf{x}_{N_0}) \end{bmatrix}_{N_0 \times L}$$

Method: 基于 RWOS-ELM 的基础分类器

OS-ELM 可以通过参数正则化和矩阵加权进一步改进 (RWOS-ELM), 以缓解在线学习期间的类别不平衡问题。 L 个隐藏节点的 RWOS-ELM 的初始输出权重矩阵 $\beta^{(0)}$ 应计算为:

$$\beta^{(0)} = \begin{cases} \mathbf{H}_0^T (\mathbf{K}_0 + \frac{\mathbf{I}}{C})^{-1} \mathbf{W}_0 \mathbf{Y}_0 & N_0 > L \\ (\mathbf{K}_0 + \frac{\mathbf{I}}{C})^{-1} \mathbf{H}_0^T \mathbf{W}_0 \mathbf{Y}_0 & N_0 < L \end{cases}$$

其中, $\mathbf{K}_0 = \mathbf{H}_0^T \mathbf{W}_0 \mathbf{H}_0$, C 是用于最小化训练误差和输出权重范数的正则化参数。 \mathbf{W}_0 是初始权重矩阵, 描述为

$$\mathbf{W}_0 = \text{diag}\{w_i\}, \quad i = 1, 2, \dots, N_0$$

第 i 个样本属于类别 c 的权重因子 w_i 定义为: $w_i = \frac{1}{N_c}$ 。 其中 N_c 是属于 c 类的样本数。

Method: 基于 RWOS-ELM 的基础分类器

在线学习过程中，RWOS-ELM 分类器在对新一批未标记输入向量进行分类后进行更新。第 $(r+1)$ 批未标记输入向量的隐藏层输出矩阵 \mathbf{H}_{r+1} 表示为：

$$\mathbf{H}_{r+1} = \begin{bmatrix} G(\mathbf{a}_1, b_1, \mathbf{x}_1^{(r+1)}) & \cdots & G(\mathbf{a}_L, b_L, \mathbf{x}_1^{(r+1)}) \\ \vdots & \ddots & \vdots \\ G(\mathbf{a}_1, b_1, \mathbf{x}_M^{(r+1)}) & \cdots & G(\mathbf{a}_L, b_L, \mathbf{x}_M^{(r+1)}) \end{bmatrix}_{M \times L}$$

其中 $\mathbf{X}^{(r+1)} = [\mathbf{x}_1^{(r+1)}, \mathbf{x}_2^{(r+1)}, \dots, \mathbf{x}_M^{(r+1)}]^T \in \mathbb{R}^{M \times n}$ 是第 $(r+1)$ 批未标记输入向量。

Method: 基于 RWOS-ELM 的基础分类器

输出权重矩阵 $\beta^{(r+1)}$ 的更新如下:

$$\beta^{(r+1)} = \beta^{(r)} + \left(\frac{\mathbf{I}}{\mathbf{C}} + \mathbf{K}_{r+1} \right)^{-1} \mathbf{H}_{r+1}^T \mathbf{W}_{r+1} \left(\bar{\mathbf{Y}}_{r+1} - \mathbf{H}_{r+1} \beta^{(r)} \right)$$

在时间 $r+1$, 输出向量表示为 $\mathbf{Y}^{(r+1)} = [\mathbf{y}_1^{(r+1)}, \mathbf{y}_2^{(r+1)}, \dots, \mathbf{y}_M^{(r+1)}]^T \in \mathbb{R}^{M \times m}$, 其中 $\mathbf{y}_i^{(r+1)}$ 对于 $i = 1, 2, \dots, M$ 是第 i 个输出向量。
矩阵 \mathbf{K}_{r+1} 定义为

$$\mathbf{K}_{r+1} = \mathbf{K}_r + \mathbf{H}_{r+1}^T \mathbf{W}_{r+1} \mathbf{H}_{r+1}$$

而 $\mathbf{W}_{r+1} = \text{diag}\{\mathbf{w}_j\}_{j=1}^M$ 。需要注意的是, 输出矩阵 $\mathbf{Y}^{(1)}$ (即 $r=0$) 对应的第一批未标记输入向量是由初始 RWOS-ELM 分类器得到的, 在线学习过程中只需要存储矩阵 \mathbf{K} 。

Method: 基于在线序列欧氏距离的辅助分类

2. 基于在线序列欧氏距离 (euclidean distance, ED) 的辅助分类器
给定初始训练样本集 \mathcal{D}_0 。计算类别 c 的初始类中心 $\bar{\mathbf{x}}_c^{(0)}$ 如下：

$$\bar{\mathbf{x}}_c^{(0)} = \frac{1}{N_c^{(0)}} \sum_{i=1}^{N_c^{(0)}} \mathbf{x}_{i,c}$$

其中， $N_c^{(0)}$ 是属于类别 c 的样本数量， $\mathbf{x}_{i,c}^{(0)}$ 是属于类别 c 的第 i 个样本。计算未标记样本与每个类别的类中心之间的欧氏距离，并通过找到最小的欧氏距离确定未标记样本的类别标签。

Method: 基于在线序列欧氏距离的辅助分类器

在对第 $(r+1)$ 批未标记样本进行分类后，更新类别 c 的类中心 $\mathbf{x}_c^{(r+1)}$ 如下：

$$\bar{\mathbf{x}}_c^{(r+1)} = \frac{\bar{\mathbf{x}}_c^{(r)} \times \sum_{u=1}^r N_c^{(u)} + \sum_{i=1}^{N_c^{(r+1)}} \mathbf{x}_{i,c}^{(r+1)}}{\sum_{u=1}^{r+1} N_c^{(u)}}$$

其中， $\mathbf{x}_{i,c}^{(r+1)}$ 是第 $(r+1)$ 批未标记样本中被分类为类别 c 的第 i 个样本， $N_c^{(u)}$ 是第 u 批未标记样本中被分类为类别 c 的样本数量。
需要注意的是，在在线学习过程中，只需要存储 $\bar{\mathbf{x}}_c^{(r+1)}$ 和 $\sum_{u=1}^{r+1} N_c^{(u)}$ 。

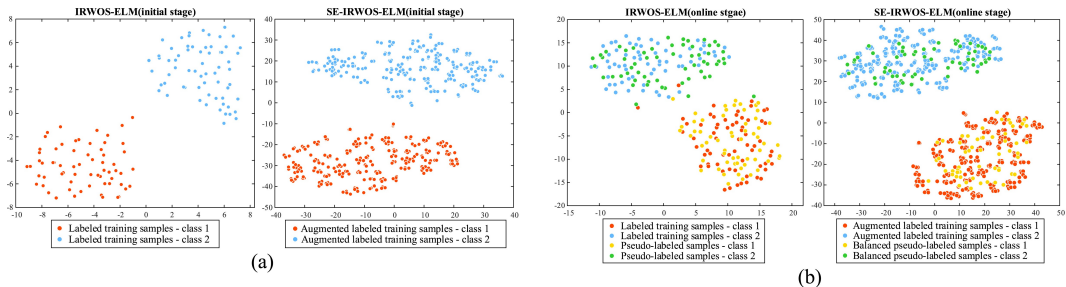


图: 数据集 2a 中受试者 8 的 IRWOS-ELM 和 SE-IRWOS-ELM 两类样本的分布。
(a) 分类器更新之前和 (b) 在线阶段最后一次更新分类器之后。所有 EEG 特征样本均通过 t-SNE 映射到 2-D 平面。

Experiments and Results

- 两个公开数据集：
 - ① BCI 竞赛 III 数据集 IVa: 5 名受试者, 118 通道, 两类 MI 任务 (右手和右脚 MI) 每类 140 次试验。随机选择 30 个试验进行评估, 每个试验 3.5 s EEG。
 - ② BCI 竞赛 IV 数据集 2a: 9 名受试者采集的 22 通道 EEG 和 3 通道 EOG 信号。四类 MI 任务 (左手、右手、左脚和右脚 MI)。每类 MI 包含 144 个试验。随机选择 38 个试验进行评估, 每个试验 3 s EEG。
- 数据预处理: EEG 数据通过 8 至 30 Hz 的带通滤波器进行滤波, 通过使用初始阶段数据得到的 4 对 CSP 空间滤波器进行空域滤波, 将带通滤波的 EEG 投影到 8 维特征空间。

Experiments and Results

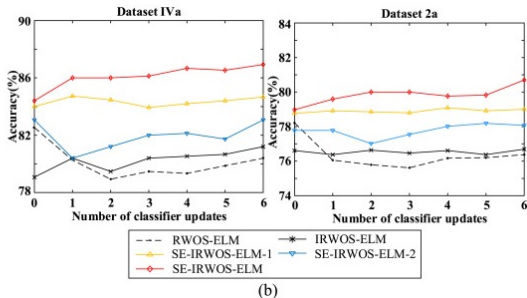
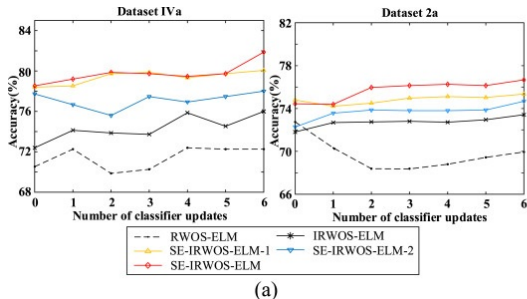


图: 数据集 IVa 和 2a 上在线阶段各受试者的平均分类准确率 (%). (a) 初始阶段使用的标记训练试验数量为 30, (b) 初始阶段使用的标记训练试验数量为 110。

Related Works I

- ① 基于朴素贝叶斯 (Naïve Bayes) 用于检测基于 EEG 中的 MI 活动 [7];
- ② FBCSP 结合 RLDA (正则化线性判别分析) 离线/在线解码站立和坐姿运动想象 EEG[5]
- ③ 稀疏贝叶斯 ELM (SBELM) MI 分类算法 [2]
- ④ 极限学习机原理及拓展介绍 [8]
- ⑤ 宽度学习系统 (BLS) 与极限学习机 (ELM)、随机向量函数链网络 (RVFLNN) 的区别与联系 [1]
- ⑥ 基于图的半监督宽度学习系统 [4]
- ⑦ 脑电信号分析中的迁移学习综述 [6]

Reference I

- [1] 宽度学习系统 (Broad Learning System, BLS) - 凯鲁嘎吉 - 博客园.
- [2] Zhichao Jin, Guoxu Zhou, Daqi Gao, and Yu Zhang.
Eeg classification using sparse bayesian extreme learning machine for brain-computer interface.
Neural Computing and Applications, 32:6601–6609, 2020.
- [3] Kai J Miller, Gerwin Schalk, Eberhard E Fetz, Marcel Den Nijs, Jeffrey G Ojemann, and Rajesh PN Rao.
Cortical activity during motor execution, motor imagery, and imagery-based online feedback.
Proceedings of the National Academy of Sciences, 107(9):4430–4435, 2010.

Reference II

- [4] Qingshan She, Yukai Zhou, Haitao Gan, Yuliang Ma, and Zhizeng Luo. Decoding eeg in motor imagery tasks with graph semi-supervised broad learning.
Electronics, 8(11):1273, 2019.
- [5] Nayid Triana-Guzman, Alvaro D Orjuela-Cañon, Andres L Jutinico, Omar Mendoza-Montoya, and Javier M Antelis. Decoding eeg rhythms offline and online during motor imagery for standing and sitting based on a brain-computer interface.
Frontiers in Neuroinformatics, 16:961089, 2022.
- [6] Zitong Wan, Rui Yang, Mengjie Huang, Nianyin Zeng, and Xiaohui Liu. A review on transfer learning in eeg signal analysis.
Neurocomputing, 421:1–14, 2021.

Reference III

- [7] Hua Wang, Yanchun Zhang, et al.
Detection of motor imagery eeg signals employing naïve bayes based learning process.
Measurement, 86:148–158, 2016.
- [8] 丘比特的帽子.
组会-极限学习机 (ELM)_ 哔哩哔哩 _bilibili.